

# 基于密度峰值聚类优化的光伏发电功率预测

王 帅, 杜欣慧, 姚宏民

(太原理工大学 电气与动力工程学院, 山西 太原 030024)

**摘要:** 密度峰值聚类算法具有收敛速度快、鲁棒性强、无需人为确定最佳聚类数等特点, 具备较好的应用前景。为提高光伏功率预测的精度, 提出一种将密度峰值聚类算法应用于短期光伏功率预测的方法, 并进行了必要优化。该方法首先通过类间距离优化增强气象数据的可分性; 然后利用密度峰值聚类对其进行无标签归类, 通过灰色关联度匹配出与待预测日相关度最高的类别; 最后将其作为 Elman 神经网络的训练样本, 得到预测结果。Matlab 仿真结果表明, 该方法能够明显提高气象数据的聚类效果, 并有效提高光伏功率的短期预测精度。

**关键词:** 密度峰值聚类; 光伏发电; 灰色关联度; 相似日匹配; Elman 神经网络; 短期功率预测

中图分类号: TN830.4-34; TM715

文献标识码: A

文章编号: 1004-373X(2018)20-0141-05

## Power prediction of photovoltaic power generation based on clustering optimization of density peaks

WANG Shuai, DU Xinhui, YAO Hongmin

(School of Electrical and Power Engineering, Taiyuan University of Technology, Taiyuan 030024, China)

**Abstract:** The density peak clustering algorithm has the characteristics of fast convergence speed, strong robustness, and no need to manually determine the optimal clustering numbers, which has a good application prospect. Therefore, a method of applying the density peak clustering algorithm to short-term photovoltaic power prediction is proposed and necessarily optimized to improve the accuracy of photovoltaic power prediction. In the method, the separability of meteorological data is enhanced by means of inter-class distance optimization. The density peak clustering is adopted to classify the meteorological data without using labels. The category that has the highest degree of correlation with to-be predicted days is matched by using the grey correlation degree, and finally taken as the training sample of the Elman neural network to obtain the prediction results. The Matlab simulation results show that the method can significantly improve the clustering effect of meteorological data and short-term prediction accuracy of photovoltaic power.

**Keywords:** density peak clustering; photovoltaic power generation; grey correlation degree; similar day matching; Elman neural network; short-term power prediction

## 0 引言

光伏发电系统因其电能可控性强, 调度管理便捷、调峰性能良好、响应迅速等优点而得到了广泛应用。但由于其输出功率受风速、气温、阳光辐射度、日降雨量、气压等气象因素影响存在较大随机波动性<sup>[1-3]</sup>, 致使有功功率不稳定而对电网造成干扰。因此, 精准的光伏发电功率预测有助于降低对电网的影响, 也便于电力工作人员的调度管理工作。

目前, 采用较多的预测方法是神经网络预测法<sup>[4-5]</sup>。即使用历史发电量与气象数据组成的训练样本训练神

经网络的自学习能力, 将待预测日的气象特征(通过数值天气预报获得)输入网络后得到预测结果。其中, 提高训练样本与待预测日的相关性极其重要。训练样本越精确、合理, 神经网络的预测结果就越准确<sup>[6]</sup>。

文献[7]通过相关性分析, 确定出影响电量的主要气象因素。利用传统的 SOM 算法对天气类型进行聚类, 然后使用对应的神经网络进行预测。但仅选取气温与湿度作为气象特征输入量, 其气象特征的综合代表性较差。当聚类数据集的特征量较多时, SOM 算法又易陷入局部最优。文献[8]在提高训练样本准确性时使用了常规算法 K-Means 聚类, 但未解决常规聚类算法收敛速度慢、需指定聚类个数、对噪声点敏感等问题。文献[9]提出一种全新聚类算法(密度峰值聚类), 几乎无需设定

参数且在大规模数据集中具有鲁棒性,能够较好地克服以上问题,具备较好的应用前景。

本文将密度峰值聚类算法应用于短期光伏功率预测,首先基于直方图均衡化原理实现类间距离优化,提高密度峰值聚类算法的有效性。然后根据聚类结果计算灰色关联度,匹配到更加准确合理的训练样本。最后,基于 Elman 神经网络得出预测结果,并对其误差进行分析。

## 1 密度峰值聚类算法及其优化

### 1.1 密度峰值聚类算法原理

密度峰值聚类算法首先明确了聚类中心的特点<sup>[9]</sup>:聚类中心的局部密度较大,其周围被一些较低密度的邻居所包围;聚类中心距离那些局部密度更大的数据点相对较远。

对数据集  $S = \{X_i\}_{i=1}^N, I_S = \{1, 2, \dots, N\}$  而言,用  $d_{ij} = \text{dist}(X_i, X_j)$  表示数据点  $X_i$  和  $X_j$  之间的距离,定义每个  $X_i$  的局部密度  $\rho_i$  与最小距离  $\delta_i$ :

#### 1.1.1 局部密度

$$\rho_i = \sum_{i,j \in I_S} f(d_{ij} - d_c) \quad (1)$$

$$f(x) = \begin{cases} 1, & x < 0 \\ 0, & x \geq 0 \end{cases} \quad (2)$$

式中: $\rho_i$  表示  $X_i$  在  $d_c$  范围内的邻居数(不计  $X_i$  本身); $d_c$  表示截断距离(根据统计学经验<sup>[9]</sup>, $d_c \in [0.01, 0.02]$ )。

#### 1.1.2 最小距离 $\delta_i$

将局部密度  $\rho_i$  按降序排列后, $\{q_i\}_{i=1}^N$  为其降序序列,则:

$$\rho_{q_1} \geq \rho_{q_2} \geq \dots \geq \rho_{q_N} \quad (3)$$

定义数据点  $X_i$  到其他更高密度的数据点的最小距离  $\delta_i$  为:

$$\delta_i = \begin{cases} \min_{j < i} \{d_{q_i q_j}\}, & i \geq 2 \\ \max_{j \geq 2} \{\delta_{q_j}\}, & i = 1 \end{cases} \quad (4)$$

此时,对于  $S$  中的任一数据点  $X_i$ ,均存在对应的  $\rho_i$  与  $\delta_i$ 。如图 1b) 所示,做出横轴为  $\rho$ ,纵轴为  $\delta$  的决策图。1 号、10 号数据点的  $\rho$  与  $\delta$  均较大(位于决策图右上方),即为聚类中心;26~28 号数据点的  $\delta$  值较大,但  $\rho$  值较小(位于决策图左侧),即为噪声数据点。

考虑到聚类中心<sup>[9]</sup>同时具备较大的  $\rho$  值与  $\delta$  值,故可通过式(5)定量分析  $\rho$  与  $\delta$ 。

$$\gamma_i = \rho_i \delta_i, i \in I_S \quad (5)$$

对  $\gamma_i$  进行降序排列,从前往后选取  $\gamma$  值具有跃变特征的数据点,作为聚类中心。而后将每个数据点归类至

距离最近的,且密度更高的数据点所属的类即可。

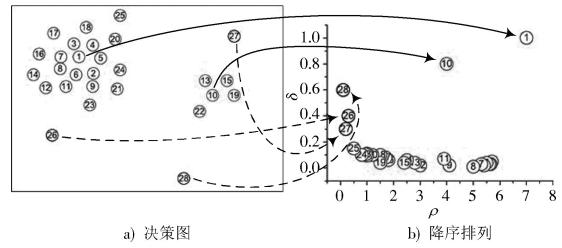


图 1 聚类原理示意图

Fig. 1 Schematic diagram of clustering principle

### 1.2 基于直方图均衡化的类间距离优化

#### 1.2.1 距离矩阵 $D$ 的定义

对于  $S = \{X_i\}_{i=1}^N$ , 每个  $X_i$  由  $W$  个点构成  $N \times W$  维特征矩阵。定义  $X_i = (i[1], i[2], \dots, i[w])$  和  $X_j = (j[1], j[2], \dots, j[w])$  之间的欧氏距离为  $d_{ij}$ :

$$d_{ij} = \sqrt{\sum_{w=1}^W (i[w] - j[w])^2} \quad (6)$$

$d_{ij}$  越小则  $X_i$  与  $X_j$  越相似。 $d_{ij}$  可按其下标组成一个主对角线为 0 的  $N \times N$  对称矩阵,即距离矩阵  $D$ 。距离矩阵可体现数据集的关联特性,下文将引用此概念。

#### 1.2.2 直方图均衡化思想的引入

在图像处理领域,常使用直方图均衡化的方法增强图像对比度,变换函数  $T(r)$  与原概率密度函数  $p_r(r)$  之间的关系为<sup>[10]</sup>:

$$s = T(r) = \int_0^r p_r(r) dr, 0 \leq r \leq 1 \quad (7)$$

式中,  $0 \leq T(r) \leq 1$ 。该变换的离散形式为:

$$s_k = T(r_k) = \sum_{i=0}^k n_i / N = \sum_{i=0}^k p_r(r_j) \quad (8)$$

可将直方图均衡化思想扩展至本文的聚类问题,即通过均衡化类簇之间的距离增强数据对比度,并提高数据可分性。

#### 1.2.3 优化过程

密度峰值聚类后各类均有唯一的中心,以类簇为整体,在保证每个类簇内部结构不变的前提下进行类间距离均衡化,能够增强数据可分性。距离扩散的程度基于式(8),示意图如图 2 所示。

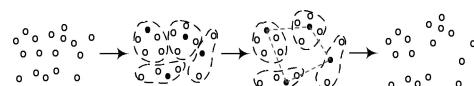


图 2 类间距离优化过程示意图

Fig. 2 Schematic diagram for optimization process of inter-class distances

#### 1.2.4 算法实现

设初始聚类中心的个数为  $K$ ,通过式(6)求出所有

聚类中心之间的距离矩阵  $D_{K \times K}$ 。再基于式(8)的原理变换后,可得到矩阵  $D'_{K \times K}$ 。

$\forall D'_{K \times K}$  中元素  $d'$ , 设其对应的两个类簇为  $\alpha$  与  $\beta$ , 即集合  $\{X_{\alpha_1}, X_{\alpha_2}, \dots, X_{\alpha_p}\}$  与  $\{X_{\beta_1}, X_{\beta_2}, \dots, X_{\beta_q}\}$  构造一个所有元素为 1 的  $N \times N$  实数矩阵。将该矩阵中脚标为  $\alpha_i, \beta_j$  与  $\beta_j \alpha_i$  的元素全部替换为  $d'$ , 其中  $i = 1, 2, \dots, p$  且  $j = 1, 2, \dots, q$ 。在此矩阵基础上遍历所有  $d'$ , 即可得到类间距离优化矩阵  $D_1$ 。定义:

$$D' = D_1 \otimes D \quad (9)$$

式中, 符号“ $\otimes$ ”代表矩阵中与脚标元素对应相乘。

由于每次被替换的元素仅属某两个类别, 既不会影响其他类间距离, 也不会影响任何类内距离。 $D'$  即为类间优化后的全新距离矩阵。

## 2 基于相似日匹配的光伏功率预测

### 2.1 结合灰色关联分析法的相似日样本匹配

在得到聚类结果后, 通过灰色关联分析法选取待预测日的相似日样本。将各类簇的气象特征向量作为比较数列, 将待预测日的气象特征向量(通过数值天气预报获得)作为参考数列。

设每个类簇  $C_{m \times n} = \{Z_k\}_{k=1}^m$  由  $m$  个比较数列、 $n$  个特征值组成,  $z_{ij}$  表示第  $i$  个对象的第  $j$  个特征值。其中  $1 \leq i \leq m$  且  $1 \leq j \leq n$ , 参考数列为  $Z_0 = (z_{01}, z_{02}, \dots, z_{0n})$ 。无纲量化后, 求取各比较数列与  $Z_0$  在各特征值上的关联系数  $\zeta_j$ :

$$\begin{aligned} \zeta_j &= \\ &\min_{1 \leq i \leq m} \left\{ \min_{1 \leq j \leq n} (|z_{ij} - z_{0j}|) \right\} + \eta \cdot \max_{1 \leq i \leq m} \left\{ \max_{1 \leq j \leq n} (|z_{ij} - z_{0j}|) \right\} \\ &|z_{ij} - z_{0j}| + \eta \cdot \max_{1 \leq i \leq m} \left\{ \max_{1 \leq j \leq n} (|z_{ij} - z_{0j}|) \right\} \end{aligned} \quad (10)$$

式中,  $\eta$  为分辨系数, 一般取 0.5。 $0 < \zeta_j \leq 1$ , 能够反映出  $Z_0$  与全部  $Z_i$  在第  $j$  个特征值上的关联程度, 求平均后得到关联度  $r_i$ :

$$r_i = \frac{1}{n} \sum_{j=1}^n \zeta_j \quad (11)$$

$r_i$  为待预测日与各比较数列的关联程度, 继续求平均得出与类簇整体的关联度  $R_l$ :

$$R_l = \frac{1}{m} \sum_{i=1}^m r_i \quad (12)$$

式中,  $l$  为类簇标号, 若共有  $L$  个类簇, 则  $1 \leq l \leq L$ 。计算  $\max_{1 \leq l \leq L} \{R_l\}$ , 代表待预测日与此类簇的关联最为紧密, 故

可将  $C_{m \times n}^l = \{Z_k\}_{k=1}^m$  作为相似日样本数据。

### 2.2 Elman 神经网络预测模型

Elman 网络可以看作是一个具有局部记忆单元和

局部反馈连接的递归神经网络, 其基本结构如图 3 所示。

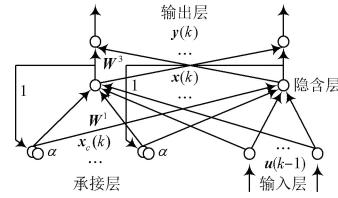


图 3 Elman 神经网络结构

Fig. 3 Structure of Elman neural network

设网络的输入  $u(k-1) \in R^r$ , 输出  $y(k) \in R^m$ , 隐含层输出  $x(k) \in R^n$ , 承接层输出  $x_c(k) \in R^n$ , 其数学模型如下:

$$x(k) = f(W^1 x_c(k) + W^2 u(k-1)) \quad (13)$$

$$x_c(k) = \alpha x_c(k-1) + x(k-1) \quad (14)$$

$$y(k) = g(W^3 x(k)) \quad (15)$$

式中:  $W^1 \in R^{n \times n}$ ,  $W^2 \in R^{n \times r}$ ,  $W^3 \in R^{m \times n}$  分别为相应层级之间的连接权矩阵;  $f(\cdot)$  与  $g(\cdot)$  分别为隐含层与输出层的非线性向量函数;  $\alpha \in [0, 1]$  为自连接反馈增益因子。

设第  $k$  步实际输出为  $\hat{y}(k)$ , 误差指标函数为:

$$E(k) = [\gamma(k) - \hat{\gamma}(k)]^T [\gamma(k) - \hat{\gamma}(k)] / 2 \quad (16)$$

网络动态学习算法为:

$$\Delta W_{ij}^3 = \eta [y_i(k) - \hat{y}_i(k)] g'_i(\cdot) x_j(k) \quad (17) \\ i = 1, 2, \dots, m; \quad j = 1, 2, \dots, n$$

$$\Delta W_{jq}^2 = \eta \sum_{i=1}^m [y_i(k) - \hat{y}_i(k)] g'_i(\cdot) W_{ij}^3 f'_j(\cdot) u_q(k-1) \quad (18) \\ j = 1, 2, \dots, n; \quad q = 1, 2, \dots, r$$

$$\Delta W_{jl}^1 = \eta \sum_{i=1}^m [y_i(k) - \hat{y}_i(k)] g'_i(\cdot) W_{ij}^3 \frac{\partial x_j(k)}{\partial W_{jl}^1} \quad (19) \\ j = 1, 2, \dots, n; \quad l = 1, 2, \dots, n$$

$$\frac{\partial x_j(k)}{\partial W_{jl}^1} = f'_j(\cdot) x_l(k-1) + \alpha \frac{\partial x_j(k-1)}{\partial W_{jl}^1} \quad (20)$$

## 3 实验结果与分析

### 3.1 聚类结果分析

构建光伏系统的气象特征量: 平均风速、气温、阳光辐射度、日降雨量、最大风速和气压。每个特征量在 5:00—19:00 内每隔 1 h 采集 1 次, 每日 15 个点, 共 180 天。归一化后形成  $180 \times 90$  维的特征矩阵, 计算距离矩阵后进行聚类分析。

首先执行传统密度峰值聚类算法如图 4 所示。聚类中心过少, 需进行优化以挖掘隐含中心。

此时, 应重新选取包括更多“疑似中心”在内的点作

为初始中心。经1.2.4节优化后得到全新距离矩阵,作出决策图与 $\gamma$ 曲线,如图5所示,优化后聚类中心增多至5个。由此表明,经过类间距离优化后,某些“隐藏类簇”被挖掘出来。

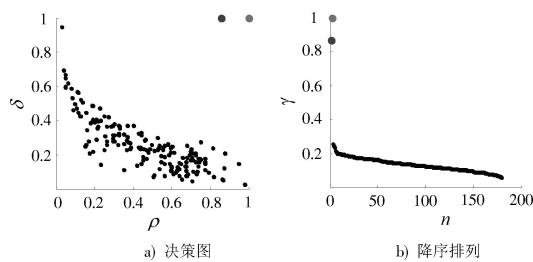


图4 优化前的决策图与降序 $\gamma$ 值

Fig. 4 Decision diagram before optimization  
and  $\gamma$  values in descending order

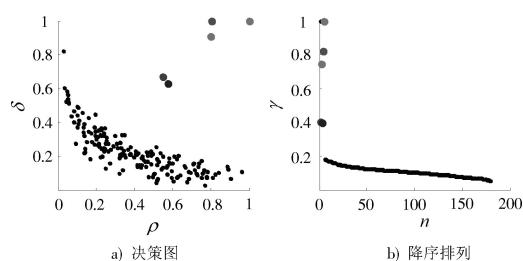


图5 优化后的决策图与降序 $\gamma$ 值

Fig. 5 Decision diagram after optimization  
and  $\gamma$  values in descending order

通过图6的直观对比可发现,经过优化后的数据可分性得到增强,聚类效果得到提升。聚类结果见表1。

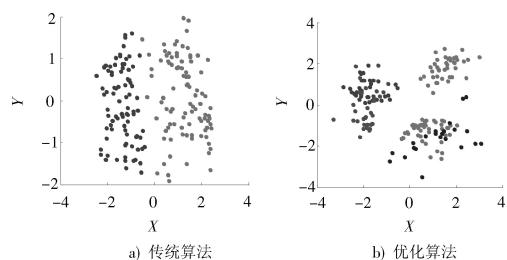


图6 在二维图中的聚类效果对比

Fig. 6 Comparison of clustering effects in 2D diagram

表1 聚类结果统计

Table 1 Statistical results of clustering

类簇	传统算法		优化算法	
	类中心编号	样本数	类中心编号	样本数
类簇1	78号	85	42号	37
类簇2	124号	95	78号	48
类簇3	—	—	94号	22
类簇4	—	—	143号	32
类簇5	—	—	156号	41
合计	2个	180	5个	180

### 3.2 聚类算法的性能分析

本文采用3种典型指标对不同时间跨度的10个数据集进行聚类有效性评价,评价结果如图7~图9所示。其中:SSE(误差平方和)代表一个子类到所在类簇的聚类中心的欧氏距离,该值越小聚类效果越好;DBI(Davies-Bouldin Index)代表所有类之间最大相似度的均值,该值越小聚类效果越好;SC(轮廓系数)结合了类簇内聚度和类间分离度两个计算指标,该值越接近1聚类效果越好。

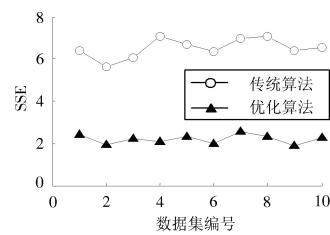


图7 SSE指标对比

Fig. 7 Comparison of SSE indexes

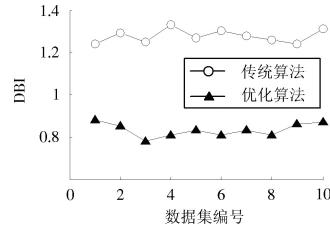


图8 DBI指标对比

Fig. 8 Comparison of DBI indexes

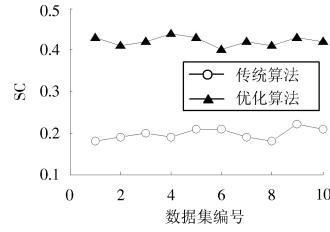


图9 SC指标对比

Fig. 9 Comparison of SC indexes

图7比较了在优化前后的SSE指标,优化后SSE明显下降;图8比较了优化前后的DBI指标,优化后DBI下降同样较为明显;图9比较了优化前后的SC指标,优化后SC出现了明显提高。由此可见,优化算法的优化性能显著,能够有效提升聚类的有效性。

### 3.3 相似日匹配与功率预测分析

得到聚类结果后,通过2.1节相似日匹配方法计算出待预测日与各类簇之间的灰色关联度 $R_l$ 。其的计算结果,如表2所示。类簇2的关联度最高,分别将其对应的气象数据与发电数据作为训练集,经Elman模型学习后得出预测结果,如图10所示。传统算法的预测结果

如图11所示。

表2 相似日样本匹配结果

Table 2 Matching results of similar day samples

类簇	类簇1	类簇2	类簇3	类簇4	类簇5
待预测日与 灰色关联度 $R_f$	0.806 7	0.824 3	0.764 2	0.741 8	0.704 7

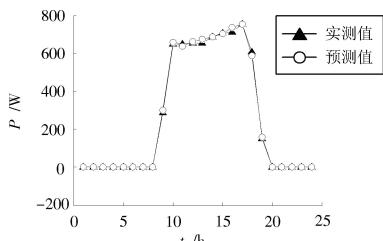


图10 经过优化聚类的光伏预测曲线

Fig. 10 Photovoltaic prediction curve after clustering optimization

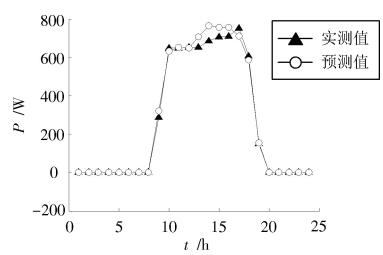


图11 传统算法的光伏预测曲线

Fig. 11 Photovoltaic prediction curve of traditional algorithm

如表3所示,采用平均绝对误差百分比(MAPE)和均方误差(MSE)评价预测结果,其原理如下:

$$I_{MAPE} = \frac{1}{Q} \sum_{i=1}^Q \left| \frac{F_a(i) - F_b(i)}{F_b(i)} \right| \times 100\% \quad (21)$$

$$I_{MSE} = \frac{1}{Q} \sum_{i=1}^Q (F_a(i) - F_b(i))^2 \quad (22)$$

式中, $F_a(i)$ 与 $F_b(i)$ 分别为预测值和实测值; $Q=24$ 为一天的采样个数。MAPE可评价预测误差大小,MSE可评价预测的整体精度。

表3 预测误差统计结果

Table 3 Statistical results of prediction errors

MAPE /%		MSE	
传统算法	优化算法	传统算法	优化算法
24.15	2.35	890.30	86.89

结合表3分析图10、图11可知,相较于传统算法,优化算法的功率预测曲线与实测曲线的契合度更高、预测误差更小(仅为2.35%),预测整体精度得到了明显提高。

## 4 结论

本文提出一种基于密度峰值聚类的短期光伏功率预测方法,详细阐述了聚类算法的原理、优化过程的具体实现步骤,以及利用聚类结果实现短期光伏功率预测的过程。实验结果表明,类间距离优化能够有效提高密度峰值聚类算法的有效性,且算法在优化后能有效提高光伏功率的短期预测精度。

## 参考文献

- [1] 嵇灵,牛东晓,汪鹏.基于相似日聚类和贝叶斯神经网络的光伏发电功率预测研究[J].中国管理科学,2015,23(3):118-122.  
JI Ling, NIU Dongxiao, WANG Peng. Photovoltaic load forecasting based on the similar day and Bayesian neural network [J]. Chinese journal of management science, 2015, 23(3): 118-122.
- [2] 杨金焕,于化丛,葛亮.太阳能光伏发电应用技术[M].北京:电子工业出版社,2009.  
YANG Jinhuan, YU Huacong, GE Liang. Application technology of solar photovoltaic power generation [M]. Beijing: Publishing House of Electronics Industry, 2009.
- [3] 周念成,闫立伟,王强钢.光伏发电在微电网中接入及动态特性研究[J].电力系统保护与控制,2010,38(14):119-127.  
ZHOU Niancheng, YAN Liwei, WANG Qianggang. Research on dynamic characteristic and integration of photovoltaic generation in microgrids [J]. Power system protection and control, 2010, 38(14): 119-127.
- [4] 王晓兰,葛鹏江.基于相似日和径向基函数神经网络的光伏阵列输出功率预测[J].电力自动化设备,2013,33(1):100-103.  
WANG Xiaolan, GE Pengjiang. PV array output power forecasting based on similar day and RBFNN [J]. Electric power automation equipment, 2013, 33(1): 100-103.
- [5] 傅美平,马红伟,毛建容.基于相似日和最小二乘支持向量机的光伏发电短期预测[J].电力系统保护与控制,2012,40(16):65-69.  
FU Meiping, MA Hongwei, MAO Jianrong. Short-term photovoltaic power forecasting based on similar days and least square support vector machine [J]. Power system protection and control, 2012, 40(16): 65-69.
- [6] 程启明,张强,程尹曼,等.基于密度峰值层次聚类的短期光伏功率预测模型[J].高电压技术,2017,43(4):1214-1222.  
CHENG Qiming, ZHANG Qiang, CHENG Yinman, et al. Short-term photovoltaic power prediction model based on hierarchical clustering of density peaks [J]. High voltage engineering, 2017, 43(4): 1214-1222.
- [7] 代倩,段善旭,蔡涛,等.基于天气类型聚类识别的光伏系统短期无辐照度发电预测模型研究[J].中国电机工程学报,2011,31(34):28-35.

(下转第149页)

糊控制的思想对输入数据进行一定程度的放缩使得误差达到 2.1%, 得到一个合适的精度, 最后通过模拟退火算法减少了训练所需的次数, 大大节省了时间。

## 4 结 论

本文在对一般的 RBF 神经网络进行分析的基础上, 采用合适的算法解决其存在的隐层节点数目的确定以及泛化能力的提高和训练算法中容易陷入局部最小值的问题。通过实验仿真结果证明上述改进将预测结果误差提高到 2% 的精度, 训练次数也大量减少。由该仿真结果可知, 通过以上算法的改进可以提高一般 RBF 神经网络的估算精度与速度, 从而达到了在实际应用过程中的需求。

注:本文通讯作者为覃团发。

## 参 考 文 献

- [1] 潘成举. 基于物联网的基站蓄电池运维及应急发电调度系统开发[D]. 南宁: 广西大学, 2015.  
PAN Chengju. Development of operation maintenance of base station's battery and emergency generation dispatching system based on Internet of Things [D]. Nanning: Guangxi University, 2015.
- [2] 余滨杉, 王社良, 杨涛, 等. 基于遗传算法优化的 SMABP 神经网络本构模型[J]. 金属学报, 2017, 53(2): 248-256.  
YU Binshan, WANG Sheliang, YANG Tao, et al. BP neural network constitutive model based on optimization with genetic algorithm for SMA [J]. Acta Metallurgica Sinica, 2017, 53(2): 248-256.
- [3] 曾谁飞, 张笑燕, 杜晓峰, 等. 基于神经网络的文本表示模型新方法[J]. 通信学报, 2017, 38(4): 86-98.
- ZENG Shuifei, ZHANG Xiaoyan, DU Xiaofeng, et al. New method of text representation model based on neural network [J]. Journal on communications, 2017, 38(4): 86-98.
- [4] WANG Qianqian, WANG Jiao, ZHAO Pengju, et al. Correlation between the model accuracy and model-based SOC estimation [J]. Electrochimica acta, 2017, 228: 146-159.
- [5] XU C, LU C, LIANG X, et al. Multi-loss regularized deep neural network [J]. IEEE transactions on circuits and systems for video technology, 2016, 26(12): 2273-2283.
- [6] TIAN Yuan, YU Yuanlong. A new pruning algorithm for extreme learning machine [C]// Proceedings of IEEE International Conference on Information & Automation. Macau: IEEE, 2017: 704-709.
- [7] SEVAKULA R K, VERMA N K. Assessing generalization ability of majority vote point classifiers [J]. IEEE transactions on neural networks & learning systems, 2017, 28(12): 2985-2997.
- [8] LI X, ZHU Y, XIA P. Enhanced analog beamforming for single carrier millimeter wave MIMO systems [J]. IEEE transactions on wireless communications, 2017, 16(7): 4261-4274.
- [9] 孟凡超, 初佃辉, 李克秋, 等. 基于混合遗传模拟退火算法的 SaaS 构件优化放置[J]. 软件学报, 2016, 27(4): 916-932.  
MENG Fanchao, CHU Dianhui, LI Keqiu, et al. Solving SaaS components optimization placement problem with hybrid genetic and simulated annealing algorithm [J]. Journal of software, 2016, 27(4): 916-932.
- [10] 李珂, 顾欣, 刘旭东, 等. 基于梯度下降法的永磁同步电机单电流弱磁优化控制[J]. 电工技术学报, 2016, 31(15): 8-15.  
LI Ke, GU Xin, LIU Xudong, et al. Optimized flux weakening control of IPMSM based on gradient descent method with single-current regulator [J]. Transactions of China Electrotechnical Society, 2016, 31(15): 8-15.

作者简介: 陈玮匀(1991—), 男, 硕士研究生, 主要研究方向为蓄电池剩余容量估算。

杨文伟(1989—), 男, 硕士研究生, 主要研究方向为认知无线电。

覃团发(1966—), 男, 博士, 教授, 主要研究方向为多媒体通信。

(上接第 145 页)

- DAI Qian, DUAN Shanxu, CAI Tao, et al. Short-term PV generation system forecasting model without irradiation based on weather type clustering [J]. Proceedings of the CSEE, 2011, 31(34): 28-35.
- [8] 丁志勇, 杨苹, 杨曦, 等. 基于连续时间段聚类的支持向量机风电功率预测方法[J]. 电力系统自动化, 2012, 36(14): 131-135.  
DING Zhiyong, YANG Ping, YANG Xi, et al. Wind power prediction method based on sequential time clustering support

作者简介: 王 帅(1991—), 男, 河北沧州人, 硕士研究生, 研究方向为电力系统运行与控制、电力数据挖掘与分析。

杜欣慧(1965—), 女, 天津人, 教授, 硕士生导师, 研究方向为电力系统运行与控制。

姚宏民(1993—), 男, 山西朔州人, 硕士研究生, 研究方向为电力系统数据分析、需求侧管理。

- vector machine [J]. Automation of electric power systems, 2012, 36(14): 131-135.
- [9] RODRIGUEZ A, LAIO A. Clustering by fast search and find of density peaks [J]. Science, 2014, 344(6191): 1492-1496.
- [10] HAN J W, KAMBER M. 数据挖掘: 概念与技术[M]. 范明, 孟小峰, 译. 北京: 机械工业出版社, 2001.  
HAN J W, KAMBER M. Data mining: concepts and techniques [M]. FAN Ming, MENG Xiaofeng, translation. Beijing: China Machine Press, 2001.